

Proyecto Final

Estimados estudiantes:

Se publica la evaluación de proyecto final correspondiente al 70% de la nota del curso, distribuida de la siguiente manera:

- 35% Manuscrito técnico
- 35% Presentación oral

El proyecto se desarrollará en grupos de **mínimo 3 estudiantes** y deberá aplicar conceptos vistos en clase:

Introducción a IA, tipos de tareas, Q-Learning, ecuación de Bellman, aprendizaje supervisado/no supervisado, regresión, clustering, redes neuronales, convolucionales, transfer learning y deep reinforcement learning (DRL).

El objetivo es que seleccionen un problema, desarrollen un notebook funcional y lo documenten mediante un manuscrito y una presentación.

Modalidades del proyecto

Cada grupo deberá escoger una de las siguientes modalidades:

Problema clásico de Machine Learning / Deep Learning

Seleccionar uno de los problemas propuestos y resolverlo con:

- Al menos dos técnicas vistas en el curso (por ejemplo: regresión, clustering, CNN, transfer learning, etc.).
- Evaluación con métricas apropiadas.
- Notebook ejecutable.

Problema de Reinforcement Learning (RL)

Resolver uno de los entornos propuestos usando Q-Learning o Deep Q-Learning.

Proyecto de temática libre (con criterios mínimos)

Los grupos pueden proponer su propio problema siempre que cumpla con los requisitos indicados mas adelante.

Problemas disponibles:

Los estudiantes podrán elegir uno de los siguientes problemas:

Clasificación de imágenes ruidosas o corrompidas (robustez algorítmica)

Dataset: CIFAR-10 con ruido sintético agregado (deben justificar cómo lo agregan). (Investigar dataset)

Tareas:

- Descargar el dataset.
- Diseñar dos modelos:
 - CNN estándar entrenada desde cero
 - Modelo con Transfer Learning (ResNet50, MobileNet, etc.)
- Entrenar bajo distintos niveles de ruido: 10%, 30%, 50%.
- Analizar gráficamente cómo cada modelo pierde robustez.
- Concluir cuál técnica “aguanta” mejor el ruido.

Detección de anomalías en series temporales (con métodos clásicos y redes neuronales)

Dataset: NAB (Numenta Anomaly Benchmark) o ECG5000 (UCR). (Investigar datasets)

Tareas:

- Crear un pipeline para detectar anomalías:
 - Método 1: técnica clásica (Isolation Forest, PCA, Local Outlier Factor, etc.)
 - Método 2: técnica profunda (Autoencoder, 1D CNN autoencoder, LSTM autoencoder, etc.)
- Comparar el método 1 y método 2: precision, recall, F1, curvas de reconstrucción.
- Visualizar ejemplos con anomalías detectadas.

Clustering avanzado + evaluación semisupervisada

Dataset: MNIST (Modified National Institute of Standards and Technology) donde la tarea no es “clasificar”, sino “clusterizar”. (Investigar dataset)

Tareas:

- Método 1: K-Means o GMM.
- Método 2: Autoencoder + clustering en el espacio latente.
- Evaluar con:

- Purity
 - NMI
 - ARI
- Visualizar el espacio latente con t-SNE o UMAP.

Transfer Learning + Fine-tuning.

Dataset: Flowers102, o Food101 (investigar dataset).

Tareas:

- Modelo 1: usar un modelo pre-entrenado personalizando la última capa sin entrenar.
- Modelo 2: fine-tuning de las últimas capas.
- Modelo 3: fine-tuning todas las capas
- Comparar eficiencia, tiempo de entrenamiento y métricas.

Optimización del Epsilon Decay en Deep Q-Learning

Entorno: CartPole o MiniGrid (Investigar entornos).

Tareas:

- Implementar DQN (desde el código base de clase es válido).
- Probar **tres estrategias**:
 - Epsilon lineal
 - Epsilon exponencial
 - Epsilon adaptativo basado en recompensa
- Analizar:
 - estabilidad
 - velocidad de convergencia
 - recompensa final
- Mostrar gráficos comparativos.

Comparación entre Q-Learning tabular vs Deep Q-Learning

Entorno: GridWorld pequeño (tabular), y luego GridWorld mayor (requiere DQN).
(Investigar entornos)

Tareas:

- Entrenar en un entorno pequeño con Q-Learning tabular.
- Aumentar tamaño del entorno → tabular ya no funciona.
- Entrenar DQN y analizar diferencias.
- Graficar políticas aprendidas y curvas de recompensa.

Proyecto Libre

Debe cumplir estas condiciones mínimas:

1. Debe incorporar dos técnicas distintas del curso, al menos una profunda.
2. Debe incluir comparación cuantitativa entre metodologías.
3. El dataset debe ser complejo o real, no trivial.
4. Para RL: debe incluir experimentos con hiperparámetros o entornos modificados.
5. Debe ser aprobado previamente con una propuesta de no menos de 10 líneas.

Entregables

A. Manuscrito (35%)

Formato libre (PDF), debe incluir:

1. Título y autores
2. Introducción breve al problema
3. Metodología (modelos empleados, justificación técnica)
4. Experimentos y resultados
5. Discusión y conclusiones
6. Repositorio GitHub o enlace al notebook

Extensión recomendada: 5 a 8 páginas.

B. Presentación (35%)

Duración: 10 minutos + 5 minutos de preguntas

Debe incluir:

- Motivación y descripción del problema
- Modelos implementados
- Resultados y visualizaciones
- Conclusiones

Rúbrica de evaluación

Manuscrito (35%)

Criterio	Puntos
Claridad y estructura	8
Justificación del problema	6

Criterio	Puntos
Calidad técnica de los modelos	8
Experimentos y evaluación	8
Discusión y conclusiones	5

Presentación (35%)

Criterio	Puntos
Claridad de la explicación	8
Dominio del tema	8
Calidad visual y organización	6
Resultados y análisis	8
Respuestas a preguntas	5

Fechas importantes

- **Entrega de propuesta de proyecto libre:** *07-diciembre-2025*
- **Presentaciones:** *12-diciembre-2025*
- **Entrega del manuscrito y notebook:** *17-diciembre-2025*